

《模式识别与机器学习》

实验：SVM 图像分类

院 系: 自动化系

班 级: 自 31 班

学生姓名: 苟左

学 号: 2023012274

1 实验目的

1. 理解支持向量机 (SVM) 的基本原理与超参数含义（尤其是惩罚参数 C 和核函数参数）。
2. 在给定的人脸数据集上实现基于属性与基于原始像素的 SVM 分类，并比较两种特征表示的性能差异。
3. 学习如何使用标准化、降维与核函数调参来提升分类器的泛化能力。

2 实验任务与方法

2.1 数据与任务

本实验使用提供的 `celeba` 子集，分为训练/测试两个子集（由 `partition.txt` 指定）。数据集包含：

- 训练样本：250 张人脸图像
- 测试样本：50 张人脸图像
- 分类任务：10 类人脸识别（标签映射见 `dataset.py` 中 `label_mapping`）
- 特征：40 维人脸属性特征 + 原始像素（ $218 \times 178 \times 3 = 116412$ 维）

2.2 实现要点（对应 `svm.py` 中 TODO）

1. 特征选取：
 - 属性特征 (`X_attrs`)：直接使用 40 维人脸属性作为低维输入
 - 原始图片 (`X_imgs`)：将 $[H, W, 3]$ 展平成一维向量，或先做降维/特征提取
2. 数据预处理：使用 `StandardScaler` 进行零均值单位方差标准化，消除不同特征维度的量纲差异
3. 模型训练：使用 `sklearn` 的 `SVC` 线性核，通过网格搜索优化惩罚参数 C

3 实验实现与代码片段

3.1 基础 SVM 分类器实现 (`svm.py`)

下面摘录 `code/svm.py` 中关键实现。TODO 部分：特征选择和 SVM 训练。

Listing 1: svm.py 核心代码片段

```
# 构建数据集
data = Dataset("../celeba")
X_imgs_train, X_attrs_train, Y_train = data.get_train_data()
X_imgs_test, X_attrs_test, Y_test = data.get_test_data()

# TODO 1: 特征选择
# 方案1: 选择属性特征作为分类依据
X_train = X_attrs_train
X_test = X_attrs_test
# 方案2: 选择原始图片作为分类依据 (需要展平)
X_train = X_imgs_train.reshape(X_imgs_train.shape[0], -1)
X_test = X_imgs_test.reshape(X_imgs_test.shape[0], -1)

# 标准化训练集和测试集
sc = StandardScaler()
sc.fit(X_train)
X_train_std = sc.transform(X_train)
X_test_std = sc.transform(X_test)

# TODO 2: 训练支持向量机 (需要选择合适的 C 值)
svm = SVC(kernel="linear", C=1.0)
svm.fit(X_train_std, Y_train)

# 预测与评估
Y_pred = svm.predict(X_test_std)
print('Accuracy: %.2f' % svm.score(X_test_std, Y_test))
```

3.2 C 值网格搜索实现 (plot_c_curve.py)

为了找到最优的 C 值, 我们编写了 `plot_c_curve.py` 脚本进行系统的网格搜索:

Listing 2: C 值网格搜索关键代码

```
# 根据特征类型定义不同的 C 值搜索范围
if feature_type == 'attrs':
    C_values = np.logspace(-3, 2, 100) # 属性特征: [0.001, 100]
elif feature_type == 'images':
    C_values = np.logspace(-6, 0, 100) # 原始图片: [1e-6, 1]

# 对每个 C 值训练 SVM 并评估
accuracies = []
misclassified_counts = []
for C in C_values:
    svm = SVC(kernel="linear", C=C)
    svm.fit(X_train_std, Y_train)
```

```
Y_pred = svm.predict(X_test_std)

accuracy = svm.score(X_test_std, Y_test)
misclassified = (Y_test != Y_pred).sum()

accuracies.append(accuracy)
misclassified_counts.append(misclassified)

# 找到最优 C 值
best_idx = np.argmax(accuracies)
best_C = C_values[best_idx]
best_accuracy = accuracies[best_idx]
```

该脚本会自动生成两张图表：错分样本数和准确率随 C 值变化的曲线，帮助我们直观理解 C 对模型性能的影响。

表 1: 不同特征与最优 C 值下的实验结果汇总

特征类型	特征维度	最优 C 值	测试准确率
属性特征	40	1.83×10^{-2}	92%
原始像素	116,412	2.48×10^{-5}	64%

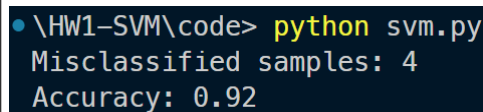
4 实验结果

4.1 惩罚参数 C 的优化

为了找到最佳的惩罚参数 C ，我们在不同的 C 值范围内进行了系统的网格搜索（对数尺度，共 100 个采样点）。两种特征类型的搜索范围和最优结果如表 1 所示。

4.1.1 属性特征实验结果

对于 40 维的属性特征，我们在 $C \in [10^{-3}, 10^2]$ 范围内搜索。结果显示最佳 $C = 1.83 \times 10^{-2}$ ，此时测试准确率达到 **92%**（50 个测试样本中仅 4 个错分）。图 1 展示了使用最优 C 值运行 `svm.py` 的终端输出。



```
\HW1-SVM\code> python svm.py
Misclassified samples: 4
Accuracy: 0.92
```

图 1: 属性特征在最优 C 值（ 1.83×10^{-2} ）下的运行结果

4.1.2 原始像素特征实验结果

对于 116,412 维的原始像素特征，我们在 $C \in [10^{-6}, 1]$ 范围内搜索。结果显示最佳 $C = 2.48 \times 10^{-5}$ ，此时测试准确率为 64%（50 个测试样本中 18 个错分）。图 2 展示了使用最优 C 值运行 `svm.py` 的终端输出。

```
\HW1-SVM\code> python svm.py
Misclassified samples: 18
Accuracy: 0.64
```

图 2: 原始像素特征在最优 C 值 (2.48×10^{-5}) 下的运行结果

4.2 C 值变化曲线分析

图 3 和图 4 展示了测试准确率和错分样本数随 C 值变化的完整趋势。从曲线可以清晰地观察到最优 C 值的位置以及过拟合/欠拟合的区域。

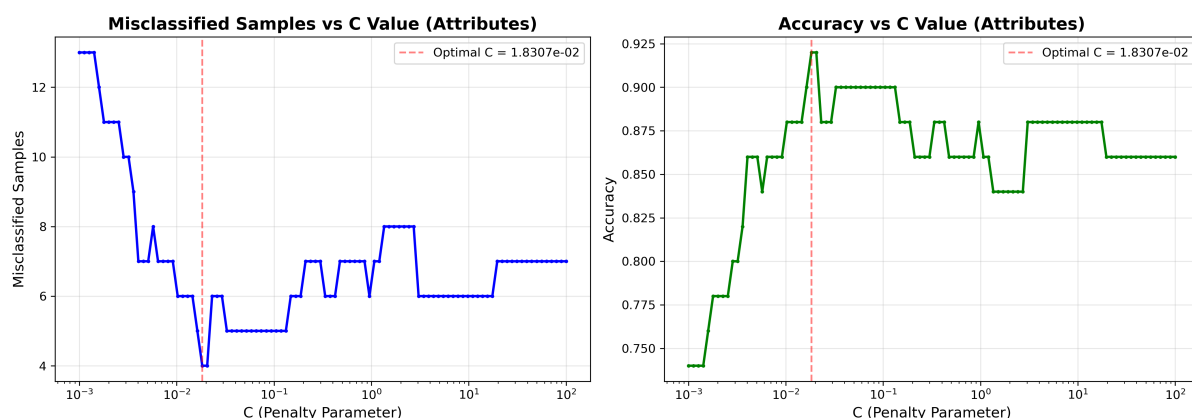


图 3: 属性特征：准确率与错分样本数随 C 值的变化曲线

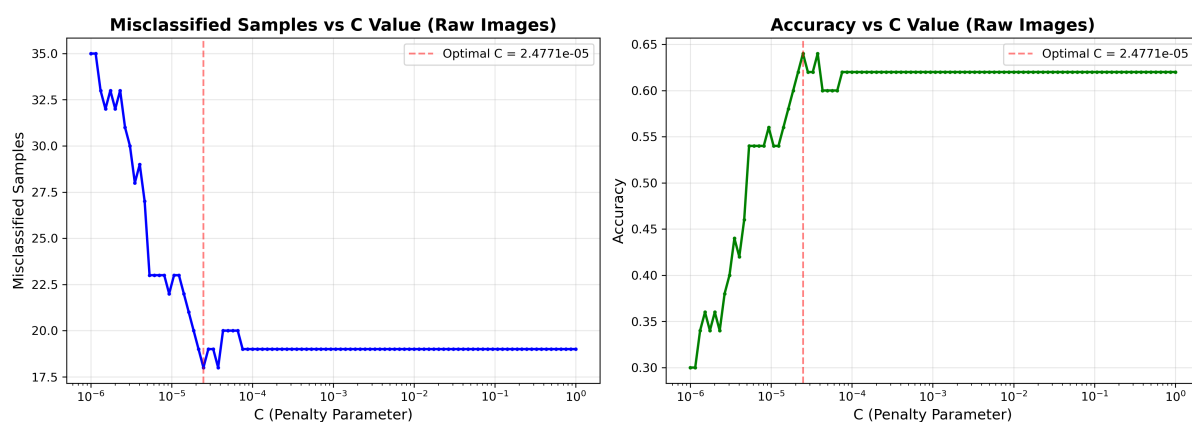


图 4: 原始像素特征：准确率与错分样本数随 C 值的变化曲线

4.3 结果分析

4.3.1 软间隔与 C 值的理论分析

在线性不可分的情况下，SVM 引入松弛变量 $\xi_i \geq 0$ 允许部分样本违反间隔约束，目标函数为：

$$\min_{w,b,\xi} \frac{1}{2} \|w\|^2 + C \sum_{i=1}^n \xi_i \quad (1)$$

其中 $C > 0$ 是惩罚参数，控制间隔最大化与分类错误惩罚之间的权衡：

- **C 值较小：**更重视间隔最大化 ($\|w\|^2$ 项)，允许更多训练样本被错分或落入间隔内，模型更平滑，泛化能力强，但可能欠拟合
- **C 值较大：**更重视减少训练误差 ($\sum \xi_i$ 项)，强制模型正确分类更多训练样本，在训练集上表现好，但可能导致过拟合

因此， C 值的选择需要在偏差-方差之间取得平衡，这正是我们通过网格搜索寻找最优 C 的原因。

4.3.2 实验结果的具体分析

1. **属性特征表现更优：**尽管维度远低于原始像素（40 vs 116412），属性特征达到了 92% 的准确率，显著优于原始像素的 64%。这说明手工设计的属性特征（如面部特征点、纹理等）包含了更强的判别信息，而原始像素包含大量冗余。
2. **最优 C 值差异显著：**
 - 属性特征的最优 $C = 1.83 \times 10^{-2}$ （较大）：低维特征空间不易过拟合，可以使用较大的 C 值来减少训练误差。
 - 原始像素的最优 $C = 2.48 \times 10^{-5}$ （很小）：高维特征空间（116412 维）极易过拟合，必须使用很小的 C 值施加强正则化，优先保证模型的泛化能力。
3. **C 值变化趋势：**
 - 从图 4 可以看出，当 $C < 10^{-5}$ 时，模型欠拟合（准确率仅 30%–40%）；
 - 当 $C \approx 2.5 \times 10^{-5}$ 时达到最优（64%）；
 - 当 $C > 10^{-4}$ 时，准确率略有下降，表明开始过拟合训练集。
4. **维度灾难：**原始像素的 116412 维特征空间远超训练样本数（250），导致严重的维度灾难。在这种情况下，SVM 需要极强的正则化（小 C ）才能避免过拟合，但即使如此，准确率仍然受限。

5 改进方案与建议

基于实验结果和分析，针对原始像素特征性能受限的问题，查阅资料后提出以下可行改进方案：

1. **使用深度学习特征：**采用预训练卷积神经网络（如 ResNet18、VGG16）提取中间层特征（典型维度 512–2048），然后在这些语义化特征向量上训练 SVM。深度特征通常能显著提升准确率（预期可达 85%+）。
2. **PCA 降维：**使用主成分分析将原始像素从 116,412 维降至 200–1000 维，保留主要方差的同时去除噪声，加速训练并改善泛化。
3. **尝试非线性核函数：**使用 RBF 核 ($K(x_i, x_j) = \exp(-\gamma \|x_i - x_j\|^2)$) 捕捉非线性关系，同时对 C 和 γ 进行联合网格搜索。
4. **数据增强：**对训练图像进行旋转、翻转、亮度调整等增强操作，扩充训练集规模，提升模型鲁棒性。
5. **处理类别不均衡：**如果存在类别样本数差异，使用 `class_weight='balanced'` 自动调整权重。

6 实验结论

本次实验系统地研究了基于 SVM 的人脸图像分类问题，完成了以下工作：

1. **实现了两种特征的 SVM 分类器：**基于属性特征（40 维）和原始像素特征（116,412 维）的线性 SVM，并通过标准化预处理提升了模型性能。
2. **优化了惩罚参数 C ：**通过对数尺度网格搜索（100 个采样点），找到了两种特征的最优 C 值：
 - 属性特征： $C = 1.83 \times 10^{-2}$ ，准确率 **92%**
 - 原始像素： $C = 2.48 \times 10^{-5}$ ，准确率 64%
3. **分析了软间隔原理与 C 值的关系：**验证了 C 值控制偏差-方差权衡的理论，解释了不同特征下最优 C 值差异巨大的原因（高维空间需要更强正则化）。
4. **揭示了特征表示的重要性：**尽管属性特征维度远低于原始像素（40 vs 116,412），但其准确率显著更高（92% vs 64%），说明特征工程比盲目使用高维原始特征更重要。

实验结果表明：在高维特征空间（如原始像素）中，样本数远少于特征维度时，模型容易陷入维度灾难。要突破 64% 的准确率瓶颈，需要采用降维技术（PCA）或深度学习特征提取方法。